

Методы понижения размерности

Машинное обучение

Наиль Баширов

Московский физико-технический институт

28 октября 2025



Сингулярное разложение

Определение


Сингулярным разложением матрицы A размера $n \times d$ является произведение трёх матриц:

$$A = U\Sigma V^\top,$$

где

- матрица U размера $n \times n$ ортогональна,
- матрица V размера $d \times d$ ортогональна,
- матрица Σ размера $n \times d$ такая, что $S_{ii} = \sigma_i = \sqrt{\lambda_i} \geq 0$, и $S_{ij} = 0$, если $i \neq j$ где $\{\lambda_i\}_{i=1}^k$ – собственные числа матрицы $A^\top A$ (и ненулевые собственные значения матрицы AA^\top).

Сингулярное разложение



Подсчёт сингулярного разложения

Пусть дана матрица A размера $n \times m$.

- ① Посчитаем AA^T (размер - $m \times m$) и A^TA (размер - $n \times n$).
- ② Находим собственные значения λ_i и собственные векторы v_i матрицы A^TA .
- ③ Найденные собственные векторы - колонки матрицы V , единственное, что остаётся сделать - запустить на них процесс Грама-Шмидта, чтобы ортонормировать их.
- ④ Корни из собственных значений λ_i и есть значения на диагонали матрицы S .
- ⑤ Ортонормированные собственные значения матрицы AA^T и есть столбцы матрицы U .

Подсчёт сингулярного разложения

Вопрос: Как можно ускорить выбранные пункты?

- ① Посчитаем AA^T (размер - $m \times m$) и A^TA (размер - $n \times n$).
- ② Находим собственные значения λ_i и собственные вектора v_i матрицы A^TA .
- ③ Найденные собственные векторы - колонки матрицы V , единственное, что остаётся сделать - запустить на них процесс Грама-Шмидта, чтобы ортонормировать их.
- ④ Корни из собственных значений λ_i есть значения на диагонали матрицы S .
- ⑤ Ортонормированные собственные значения матрицы AA^T есть столбцы матрицы U .

Подсчёт сингулярного разложения: шаги 2-3

Обычно, вместо процесса нахождения собственных значений и векторов (которое крайне затратно), используется алгоритм с образом матрицы, а именно:

- Засэмплировать матрицу Ω , состоящую из нормальных гауссовых векторов;
- Найти образ этих векторов $Y = A\Omega$;
- Применить QR-разложение: $Y = QR$, где Q – ортогональная, а R – верхнетреугольная;
- Вычислить SVD для матрицы $R = U\Sigma V^T$;
- Матрица QU - искомая ортогональная.

Подсчёт сингулярного разложения: шаг 5

Замечание: собственные значения матриц $A^T A$ и AA^T связаны. Если мы уже посчитали первое, то можем посчитать второе исходя из первого.

$u_i = \frac{1}{\sqrt{\lambda_i}} A v_i$, где u_i - столбец U , v_i - столбец матрицы V , λ_i - соответствующее собственное значение.

Приложения сингулярного разложения


- Решение обратных задач и вычисление псевдообратной матрицы;
- Понижение размерности (PCA - метод главных компонент);
- Латентно-семантический анализ (LSA) в обработке естественного языка (NLP);
- Сжатие изображений;
- Подавление шума в обработке сигналов;
- Рекомендательные системы;

Мотивация

Задача: распознать цифры на картинке.



Датасет состоит из картинок размера 28×28 пикселей. Все картинки в черно-белом, так что каждый пиксель принимает значение от 0 до 255. Это можно трактовать как датасет на $28 * 28 = 784$ параметра.



Датасет: MNIST dataset

Постановка задачи снижения размерности данных

Пусть x^1, x^2, \dots, x^n - выборка в пространстве \mathbb{R}^d .

Мы хотим выбрать пространство меньшей размерности $k < d$ так, чтобы если расстояние между объектами выборки по некоторой метрике было маленьким, осталось сравнительно маленьким, а если было большим - осталось большим.

Причины понижения размерности

- уменьшение вычислительных затрат;
- сжатие данных для более эффективного хранения информации;
- борьба с зависимыми признаками;
- борьба с переобучением;
- визуализация и интерпретация данных

Метод главных компонент (PCA)

Пусть x^1, x^2, \dots, x^n - выборка в пространстве \mathbb{R}^d . Соберём из объектов выборки матрицу X размера $n \times d$.

Хотим перейти от матрицы X к матрице $Z \in \mathbb{R}^{n \times k}$, $k < d$.

Метод главных компонент (PCA)

Пусть x^1, x^2, \dots, x^n - выборка в пространстве \mathbb{R}^d . Соберём из объектов выборки матрицу X размера $n \times d$.

Хотим перейти от матрицы X к матрице $Z \in \mathbb{R}^{n \times k}$, $k < d$.

Помимо этого, мы хотим, чтобы старые признаки восстанавливались по новым с приемлемой точностью, т. е. существует матрица $V = (v_j^i)$ размера $d \times k$ такая, что

$$\hat{x}^i = \sum_{l=1}^k v_l^i z_l \quad \approx \quad x^i.$$

Метод главных компонент (PCA)

Пусть x^1, x^2, \dots, x^n - выборка в пространстве \mathbb{R}^d . Соберём из объектов выборки матрицу X размера $n \times d$.

Хотим перейти от матрицы X к матрице $Z \in \mathbb{R}^{n \times k}$, $k < d$.



Помимо этого, мы хотим, чтобы старые признаки восстанавливались по новым с приемлемой точностью, т. е. существует матрица $V = (v_j^i)$ размера $d \times k$ такая, что

$$\hat{x}^i = \sum_{l=1}^k v_l^i z_l \quad \approx \quad x^i.$$

Из условий выше легко записывается задача оптимизации:

$$\Delta^2(Z, V) = \sum_{j=1}^k \|\hat{x}^j - x^j\|^2 = \|X - ZV^\top\|_F^2 \rightarrow \min_{Z, V}$$

PCA на MNIST



Свойства метода

Теорема

Если $k < \text{rank}(X)$, то минимум $\Delta^2(Z, V)$ достигается, когда столбцы матрицы V есть собственные векторы матрицы $X^\top X$, соответствующие k максимальным собственным значениям этой матрицы. При этом $Z = XV$, а матрицы V и Z – ортогональны.

Свойства метода

Теорема

Если $k < \text{rank}(X)$, то минимум $\Delta^2(Z, V)$ достигается, когда столбцы матрицы V есть собственные векторы матрицы $X^\top X$, соответствующие k максимальным собственным значениям этой матрицы. При этом $Z = XV$, а матрицы V и Z – ортогональны.

Доказательство:

- Из условий минимума получаем:

$$Z = XV(V^\top V)^{-1}, \quad V = X^\top Z(Z^\top Z)^{-1}.$$

- Решение задачи определено с точностью невырожденного преобразования R : $ZV^\top = (ZR)(R^{-1}V^\top)$.
- Выберем R так, чтобы матрица $Z^\top Z$ была диагональной, а $V^\top V$ – ортогональной (такое преобразование существует).

Свойства метода

Доказательство (продолжение):

- Тогда уравнение из условия минимума сводится к

$$Z = XV, \quad V\Lambda = X^T Z.$$

- Подставляя первое во второе получаем: $V\Lambda = X^T XV$, то есть V составлено из собственных векторов матрицы $X^T X$.
- Аналогично $Z\Lambda = XX^T Z$, то есть Z составлено из собственных векторов матрицы XX^T .
- Подставляя в задачу минимизации:

$$\Delta^2(Z, V) = \text{Tr} \left[(X - ZV^T)(X - ZV^T)^T \right] = \|X\|_F^2 - \text{Tr} \left[V\Lambda V^T \right].$$

Свойства метода

Теорема

Если $k < \text{rank}(X)$, то минимум $\Delta^2(Z, V)$ достигается, когда столбцы матрицы V есть собственные векторы матрицы $X^\top X$, соответствующие k максимальным собственным значениям этой матрицы. При этом $Z = XV$, а матрицы V и Z – ортогональны.

Свойства метода

Теорема

Если $k < \text{rank}(X)$, то минимум $\Delta^2(Z, V)$ достигается, когда столбцы матрицы V есть собственные векторы матрицы $X^\top X$, соответствующие k максимальным собственным значениям этой матрицы. При этом $Z = XV$, а матрицы V и Z – ортогональны.

Свойства матриц V и Z :

- ① Матрица V ортонормирована, т.е. $V^\top V = I$;
- ② $Z^\top Z = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_k)$, где $\lambda_1 \geq \dots \geq \lambda_k - k$ максимальных собственных значений матрицы $X^\top X$.
- ③ $X^\top XV = V\Lambda$, $X^\top Z = Z\Lambda$;
- ④ $\|ZV^\top - X\|_F^2 = \|X\| - \text{tr}(\Lambda) = \sum_{j=k+1}^d \lambda_j$.

Выбор количества признаков

Наблюдение

Пусть

$$E_k = \frac{\sum_{j=k+1}^d \lambda_j}{\sum_{j=1}^d \lambda_j}.$$

Чем меньше E_k , тем лучше новые признаки приближают старые.

Выбор количества признаков

Наблюдение

Пусть



$$E_k = \frac{\sum_{j=k+1}^d \lambda_j}{\sum_{j=1}^d \lambda_j}.$$

Чем меньше E_k , тем лучше новые признаки приближают старые.

- $\tilde{k} = \min_k E_k < \varepsilon$ - эффективная размерность пространства признаков X .
- **Метод локтя:** Упорядочим собственные значения по убыванию. Если E_{k+1} достаточно мало и $E_k \gg E_{k+1}$, то в качестве эффективной размерности берем k .
- **Метод сломанной трости:** $\bar{k} = \inf\{k : \frac{\lambda_k}{\sum_{i=1}^k \lambda_i} < \frac{1}{d} \sum_{j=k}^d \frac{1}{j}\}$

Метод локтя/метод крутого склона

Метод локтя vs. Метод сломанной трости



Главные компоненты

Главные компоненты – это собственные векторы матрицы $X^T X$, соответствующие k максимальным собственным значениям этой матрицы.

В качестве новых признаков $\{z_j\}_{j=1}^k$ модели мы выбираем проекции старых объектов на эти собственные векторы.

Вероятностная интерпретация: Проекции объектов на первую главную компоненту c_1 имеют наибольшую выборочную дисперсию среди проекций на всевозможные направления $d \in \mathbb{R}^k$.

Далее, $\forall j \geq 2$ проекции объектов на c_j – j -тую главную компоненту – имеют наибольшую выборочную дисперсию среди проекций на всевозможные направления $d \in \mathbb{R}^k$, перпендикулярные c_1, \dots, c_{j-1} .

Особенности метода главных компонент


- Выбросы могут сильно помешать работе алгоритма, поэтому стоит их удалить.
- Если 2 признака имеют очень большую корреляцию, то один из признаков тоже стоит удалить, иначе матрицы будут плохо обращаться.
- Если признаки в различных шкалах, то **стандартизация данных обязательна**.
- PCA является инвариантным относительно поворота координат в пространстве переменных.
- PCA завязан на собственных значениях у матриц. Собственные значения могут быть кратными. Если некоторые собственные значения матрицы $X^T X$, совпали, то новое пространство признаков может определяться неоднозначно. При этом, если все собственные значения различны, то мы будем выделять линейные подпространства исходного пространства.

Нелинейные методы понижения размерности

- **Kernel PCA:** вместо стандартного скалярного произведения рассмотрим скалярное произведение $K(x, y) = \langle \varphi(x), \varphi(y) \rangle$ - тут всё по аналогии с SVM и ядрами там.
- **Многомерное шкалирование (MDS):** не использует значения x^i , а лишь разницу между ними, чтобы минимизировать разницу между расстояниями $|\rho(x^i, x^j) - \rho(z^i, z^j)|$ при переходе между пространствами; удобен для задач, в которых тяжело отбирать признаки (например, для картинок).
- **Isomap:** тот же самый PCA, только вместо евклидового расстояния берется геодезическое, которое дает более обширную характеристику в пространстве признаков.


Нелинейные методы понижения размерности

Original S-curve




Dimensionality Reduction: PCA, MDS, Isomap (1000 points, 10 neighbors)


PCA (0 sec)



MDS (1.9 sec)



Isomap (0.46 sec)



t-SNE

t-SNE (t-distributed Stochastic Neighbor Embedding) – один из алгоритмов понижения размерности, в частности, хорошо подходящий для визуализации данных.

Постановка задачи снижения размерности данных

Задача Снижение размерности данных

Пусть x^1, x^2, \dots, x^n - выборка в пространстве \mathbb{R}^d . Хотим перейти от признаков X к новым признакам $Z = (z_j^i)$, где Z -матрица размера $n \times k$, $k < d$.

Наша цель - отобразить кластерную структуру, сохранив кластеры без сохранения пространственных взаимоотношений кластеров.

SNE

Определим вероятность того, что x^j - сосед x^i , пропорционально плотности $\mathcal{N}(x^i, \sigma_i^2)$ в точке x^j :

$$p_{j|i} = \frac{\exp(-\|x^j - x^i\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x^j - x^k\|^2 / 2\sigma_i^2)}.$$

SNE

Определим вероятность того, что x^j - сосед x^i , пропорционально плотности $\mathcal{N}(x^i, \sigma_i^2)$ в точке x^j :

$$p_{j|i} = \frac{\exp(-\|x^j - x^i\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x^j - x^k\|^2 / 2\sigma_i^2)}.$$

Определим вероятность того, что z^j - сосед z^i , пропорционально плотности $\mathcal{N}(z^i, 1/2)$ в точке z^j :

$$q_{j|i} = \frac{\exp(-\|z^j - z^i\|^2)}{\sum_{k \neq i} \exp(-\|z^j - z^k\|^2)}.$$

Будем считать, что $p_{i|i} = 0$ и $q_{i|i} = 0$.

Как выбирать σ_i^2

Тогда **энтропия** имеет вид: $H(\sigma_i) = -\sum_{j=1}^n p_{j|i} \log p_{j|i}$.

Перплексия $\text{Perp}(\sigma_i) = 2^{H(\sigma_i)}$ имеет смысл сглаженного показателя эффективного числа соседей точки X_i .

Значение перплексии — гиперпараметр метода. Задается одинаковым для всех i . Числа σ_i подбираются на основе перплексии с помощью бинарного поиска.

Вопрос: Зачем делать разные σ_i ?

Как выбирать σ_i^2

Тогда **энтропия** имеет вид: $H(\sigma_i) = -\sum_{j=1}^n p_{j|i} \log p_{j|i}$.

Перплексия $\text{Perp}(\sigma_i) = 2^{H(\sigma_i)}$ имеет смысл сглаженного показателя эффективного числа соседей точки X_i .

Значение перплексии — гиперпараметр метода. Задается одинаковым для всех i . Числа σ_i подбираются на основе перплексии с помощью бинарного поиска.

Вопрос: Зачем делать разные σ_i ?

Разная σ_i необходима из-за возможного наличия кластеров разных плотностей.

Оптимизационная задача

Хотим выбрать z^1, z^2, \dots, z^n так, чтобы вероятности $q_{j|i}$ как можно точнее описывали $p_{j|i}$.

Функция потерь: дивергенция Кульбака-Лейблера между $p_{j|i}$ и $q_{j|i}$

$$\mathcal{L}(P, Q) = \sum_{i=1}^n \text{KL}(P_i \parallel Q_i) = \sum_{i=1}^n \sum_{j=1}^n p_{j|i} \log \frac{p_{j|i}}{q_{j|i}} \rightarrow \min_Z$$

Вопрос: одинаковые ли штрафы, если близкие точки расположены далеко и далекие точки расположены близко?

Оптимизационная задача

Хотим выбрать z^1, z^2, \dots, z^n так, чтобы вероятности $q_{j|i}$ как можно точнее описывали $p_{j|i}$.

Функция потерь: дивергенция Кульбака-Лейблера между $p_{j|i}$ и $q_{j|i}$

$$\mathcal{L}(P, Q) = \sum_{i=1}^n \text{KL}(P_i \parallel Q_i) = \sum_{i=1}^n \sum_{j=1}^n p_{j|i} \log \frac{p_{j|i}}{q_{j|i}} \rightarrow \min_Z$$

Вопрос: одинаковые ли штрафы, если близкие точки расположены далеко и далекие точки расположены близко?

- большой штраф, если близкие точки будут расположены далеко.
- малый штраф, если далекие точки будут расположены близко.

Симметричный SNE

Рассмотрим «симметричные» вероятности:

$$p_{ji} = \frac{\exp(-\|x^j - x^i\|^2 / 2\sigma_i^2)}{\sum_{j \neq i} \exp(-\|x^j - x^i\|^2 / 2\sigma_i^2)}, \quad q_{ji} = \frac{\exp(-\|z^j - z^i\|^2)}{\sum_{j \neq i} \exp(-\|z^j - z^i\|^2)}$$

причем $p_{ii} = q_{ii} = 0$

Функция потерь

$$\mathcal{L}(P, Q) = \text{KL}(P \parallel Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}.$$

Если x_i - выброс, то $\|x^i - x^j\| \gg 0$ и $p_{ij} \approx 0$ для любого j . Значит расположение z^i почти не влияет на \mathcal{L} .

Симметричный SNE

Рассмотрим «симметричные» вероятности:

$$p_{ji} = \frac{\exp(-\|x^j - x^i\|^2 / 2\sigma_i^2)}{\sum_{j \neq i} \exp(-\|x^j - x^i\|^2 / 2\sigma_i^2)}, \quad q_{ji} = \frac{\exp(-\|z^j - z^i\|^2)}{\sum_{j \neq i} \exp(-\|z^j - z^i\|^2)}$$

причем $p_{ii} = q_{ii} = 0$

Функция потерь

$$\mathcal{L}(P, Q) = \text{KL}(P \parallel Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}.$$

Если x_i - выброс, то $\|x^i - x^j\| \gg 0$ и $p_{ij} \approx 0$ для любого j . Значит расположение z^i почти не влияет на \mathcal{L} .

Вместо этого определим p_{ij} как $p_{ij} = \frac{p_{i|j} + p_{j|i}}{2n}$. Тогда $\sum_j p_{ij} > 1/2n$.


Crowding problem

При вложении в пространство малой размерности при использовании нормального распределения действуют силы сжатия, из-за чего точки сильно сжимаются в кучу.

Пример

Данные: облака точек в вершинах правильного тетраэдра в \mathbb{R}^3 . В силу симметричности при сжатии в \mathbb{R}^2 на точки будут действовать "сжимающие силы" по диагоналям.

Визуализация Crowding problem



Мы не можем поставить в новом пространстве точку H_4 так, чтобы она был на расстоянии 1 и от H_1 , и от H_3 .

t-SNE

Для снижения частоты возникновения Crowding problem определим q_{ij} на основе распределения Стьюдента:



$$q_{ji} = \frac{(1 + \|z^i - z^j\|^2)^{-1}}{\sum_{i \neq j} (1 + \|z^i - z^j\|^2)^{-1}}$$

При этом $p_{ij} = \frac{p_{i|j} + p_{j|i}}{2n}$. Градиент в таком случае

$$\frac{\partial \mathcal{L}}{\partial z^i} = 4 \sum_j^n \frac{(p_{ij} - q_{ij})(z^i - z^j)}{1 + \|z^i - z^j\|^2}$$

- Градиент делится на квадрат расстояния плюс 1.
- Если точки близки, то $\|z^i - z^j\|^2 \approx 0$, и сила остается прежней.
- Если точки далеки, то $\|z^i - z^j\|^2 \gg 0$, сила сжатия становится существенно меньше, и сильного сжатия не происходит.

Сравнение PCA и t-SNE на MNIST



UMAP

Uniform Manifold Approximation and Projection — метод, выполняющий нелинейное снижение размерности. Алгоритм предложен в 2018 году с целью получить аналог t-SNE, но с более сильным математическим обоснованием.

Ориентированный граф

Пусть $X = (x^1, x^2, \dots, x^n)$ - выборка в пространстве \mathcal{X} .
 $\rho(x, y)$ - метрика в \mathcal{X} .

Определим случайный ориентированный граф на множестве вершин X . Считаем, что каждое ребро появляется независимо от других.

Пусть $x^{i_1}, x^{i_2}, \dots, x^{i_k}$ - k ближайших соседей объекта x^i в выборке X .
 $r_i = \min_s \rho(x^i, x^{i_s})$ — расстояние до ближайшего соседа.

Вероятность ребра из x^i в x^{i_s} (для остальных ноль):

$$\mathbb{P}\{x^i \rightarrow x^{i_s}\} = \exp\left(-\frac{\rho(x^i, x^{i_s}) - r_i}{\sigma_i}\right),$$

где σ_i определяется как решение уравнения $\sum_{s=1}^k \mathbb{P}\{x^i \rightarrow x^{i_s}\} = \log_2 k$

Неориентированный граф

На основе ориентированного графа построим неориентированный. X — множество вершин. Вероятность ребра между x^i и x^{i_s} :

$$\begin{aligned}\mathbb{P}\{x^i \leftrightarrow x^{i_s}\} &= \mathbb{P}\left(\{x^i \rightarrow x^{i_s}\} \cup \{x^{i_s} \rightarrow x^i\}\right) \\ &= \mathbb{P}\{x^i \rightarrow x^{i_s}\} + \mathbb{P}\{x^{i_s} \rightarrow x^i\} - \mathbb{P}\{x^i \rightarrow x^{i_s}\} \mathbb{P}\{x^{i_s} \rightarrow x^i\}\end{aligned}$$

Новые признаки

Пусть z^1, z^2, \dots, z^n - новые признаки, которые хотим получить.

На них определяем случаем неориентированный граф с вероятностями $\mathbb{P}\{z^i \leftrightarrow z^j\} = (1 + a\|z^i - z^j\|_2^{2b})^{-1}$, где a и b - гиперпараметры.

Минимизируем дивергенцию Кульбака-Лейблера:


$$\begin{aligned} \text{KL}(\mathbb{P}_x \parallel \mathbb{P}_z) &= \sum_{i,j} \left[\mathbb{P}\{x^i \leftrightarrow x^j\} \log \frac{\mathbb{P}\{x^i \leftrightarrow x^j\}}{\mathbb{P}\{z^i \leftrightarrow z^j\}} \right. \\ &\quad \left. + (1 - \mathbb{P}\{x^i \leftrightarrow x^j\}) \log \frac{1 - \mathbb{P}\{x^i \leftrightarrow x^j\}}{1 - \mathbb{P}\{z^i \leftrightarrow z^j\}} \right] \end{aligned}$$

Свойства UMAP


- Введение графов и вероятностей на них эквивалентно использованию метрики локальной связности, которая устойчива к проклятию размерности. UMAP можно применять на данных огромных размерностей.
- Возможно сохранение пространственных взаимоотношений между кластерами.
- Можно применять на новых данных и выполнять обратное преобразование.
- Работает в несколько раз быстрее t-SNE.
- Поддерживает различные метрики.

Сравнение t-SNE и UMAP на MNIST

Визуализация MNIST после t-SNE



Визуализация MNIST после UMAP



Пример

4 миллиона транскриптомов отдельных клеток взрослого мозга мыши, помеченных по исходному региону мозга и представленных с помощью UMAP (Yao Z. et al., 2023, bioRxiv).

